The background of the slide features a complex network diagram with numerous nodes connected by lines, creating a web-like structure. The nodes and lines are rendered in a light blue color against a dark blue background.

# Aprendizaje de **Máquina Supervisado**

---

Sesión 1

---

# Métricas de Desempeño de un Algoritmo

Exploraremos las principales herramientas para evaluar tanto algoritmos de regresión como de clasificación, analizando sus fórmulas, interpretaciones y aplicaciones prácticas.

A lo largo de esta presentación, veremos cómo medir la precisión de nuestros modelos y entender sus fortalezas y debilidades a través de métricas cuantitativas que nos permiten tomar decisiones informadas.



# Error Absoluto Medio (MAE)

## 1 Definición

El MAE mide el promedio de los errores absolutos entre los valores reales ( $y_i$ ) y los valores predichos ( $\hat{y}_i$ ) por el modelo. A diferencia del MSE, no eleva al cuadrado los errores, lo que lo hace menos sensible a valores atípicos.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

## 2 Fórmula

$\text{MAE} = (1/n) \sum |y_i - \hat{y}_i|$ , donde  $n$  es el número total de observaciones,  $y_i$  es el valor real y  $\hat{y}_i$  es el valor predicho.

## 3 Ventajas

Es menos sensible a valores atípicos, fácil de interpretar y no penaliza en exceso los errores grandes. Tiene la misma unidad que la variable de salida, facilitando su interpretación en el contexto del problema.

# Error Cuadrático Medio (MSE)

## Definición

El MSE es una métrica ampliamente utilizada que eleva al cuadrado los errores entre los valores reales y los predichos, penalizando más los errores grandes. Esto lo hace más sensible a valores atípicos, ya que los errores grandes tienen un impacto desproporcionado.

## Fórmula

$MSE = (1/n) \sum (y_i - \hat{y}_i)^2$ , donde  $n$  es el número total de observaciones,  $y_i$  es el valor real y  $\hat{y}_i$  es el valor predicho.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

## Interpretación

Un MSE más bajo indica mejor ajuste del modelo. Sin embargo, tiene unidades cuadradas de la variable de salida, lo que puede dificultar su interpretación en el contexto del problema.



# Raíz del Error Cuadrático Medio (RMSE)

## Definición

El RMSE es la raíz cuadrada del MSE, lo que la convierte en una medida de error que tiene las mismas unidades que la variable de salida. Esto facilita su interpretación en el contexto del problema.


## Fórmula

$RMSE = \sqrt{[(1/n) \sum (y_i - \hat{y}_i)^2]}$ , donde  $n$  es el número total de observaciones,  $y_i$  es el valor real y  $\hat{y}_i$  es el valor predicho.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

## Ventajas

Tiene las mismas unidades que la variable de salida, lo que lo hace más interpretable que el MSE. Penaliza los errores grandes y es ampliamente utilizado en problemas de regresión.



# Coeficiente de Determinación ( $R^2$ )



## Interpretación

Un valor cercano a 1 indica que el modelo explica gran parte de la varianza. Un valor cercano a 0 indica mal ajuste. Un valor negativo es posible cuando el modelo es peor que uno que siempre predice la media.



## Definición

El  $R^2$  mide la proporción de la varianza en la variable dependiente que es explicada por el modelo. Varía entre 0 y 1, donde un valor cercano a 1 indica que el modelo explica gran parte de la varianza.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$



## Ventajas

Tiene interpretación intuitiva, permite comparar diferentes modelos y no depende de la escala. Es una métrica adimensional, facilitando su uso en diferentes contextos.

# Confusion Matrix



False positive

# Matriz de Confusión

	Predicción Negativa (0)	Predicción Positiva (1)
Real Negativo (0)	Verdaderos Negativos (VN)	Falsos Positivos (FP)
Real Positivo (1)	Falsos Negativos (FN)	Verdaderos Positivos (VP)

La matriz de confusión es una tabla que resume el desempeño de un modelo de clasificación al comparar las predicciones con los valores reales. Es especialmente útil para problemas de clasificación binaria, pero puede extenderse a problemas multiclase.

Los elementos de la matriz son: Verdaderos Positivos (VP), Falsos Positivos (FP), Falsos Negativos (FN) y Verdaderos Negativos (VN). Cada uno representa diferentes tipos de aciertos y errores del modelo.




# PRECISION VS ACCURACY

Precision and accuracy target the accuracy and precision in the prediction hit rates of accuracy, de. accuracy be for cholf the precision are of the motting are hecorencial of untes, is your nnationurate of the sigulderdsad in acclunratios acturagy and accuracy.



Overativly precisim this precidatn and blacouricy, and excuiston as rane, acttion, and vatlle hit a, rate in their llicerat in the accuracy, is home with hit rgain oescllicition anent the juch accury in incllating and accuracy in querates in accuracy.



# Precisión y Exactitud

1

## Precisión

Mide la proporción de predicciones positivas que son correctas. Fórmula:  $\text{Precisión} = \frac{VP}{VP + FP}$ . Es útil cuando los falsos positivos son costosos o no deseables.

$$\text{Precisión} = \frac{VP}{VP + FP}$$

2

## Exactitud

Mide la proporción de predicciones correctas sobre el total. Fórmula:  $\text{Exactitud} = \frac{VP + VN}{VP + FP + VN + FN}$ . Es una métrica general del desempeño global del modelo.

$$\text{Exactitud} = \frac{VP + VN}{VP + FP + VN + FN}$$

3

## Interpretación

Un valor alto de precisión indica pocos falsos positivos. Un valor alto de exactitud indica muchas predicciones correctas, aunque puede ser engañosa en conjuntos de datos desbalanceados.



# Sensibilidad y Especificidad

## Sensibilidad (Recall) 1

Mide la proporción de casos positivos que el modelo identificó correctamente. Fórmula:  $\text{Sensibilidad} = \text{VP} / (\text{VP} + \text{FN})$ . Es importante cuando los falsos negativos son críticos, como en diagnóstico médico.

$$\text{Sensibilidad} = \frac{\text{VP}}{\text{VP} + \text{FN}}$$

## 2 Especificidad

Mide la proporción de casos negativos que el modelo identificó correctamente. Fórmula:  $\text{Especificidad} = \text{VN} / (\text{VN} + \text{FP})$ . Es importante cuando los falsos positivos son costosos.

$$\text{Especificidad} = \frac{\text{VN}}{\text{VN} + \text{FP}}$$

## Equilibrio 3

Existe un compromiso entre sensibilidad y especificidad. Aumentar una generalmente disminuye la otra. El umbral óptimo depende del contexto específico del problema y los costos asociados a cada tipo de error.

# Curva ROC y AUC

## Curva ROC

Gráfica que muestra la relación entre la tasa de verdaderos positivos (Sensibilidad) y la tasa de falsos positivos (1-Especificidad) para diferentes umbrales.



## AUC

El Área Bajo la Curva ROC cuantifica el rendimiento general del modelo. Un AUC de 1.0 indica un clasificador perfecto, mientras que 0.5 equivale a un clasificador aleatorio.

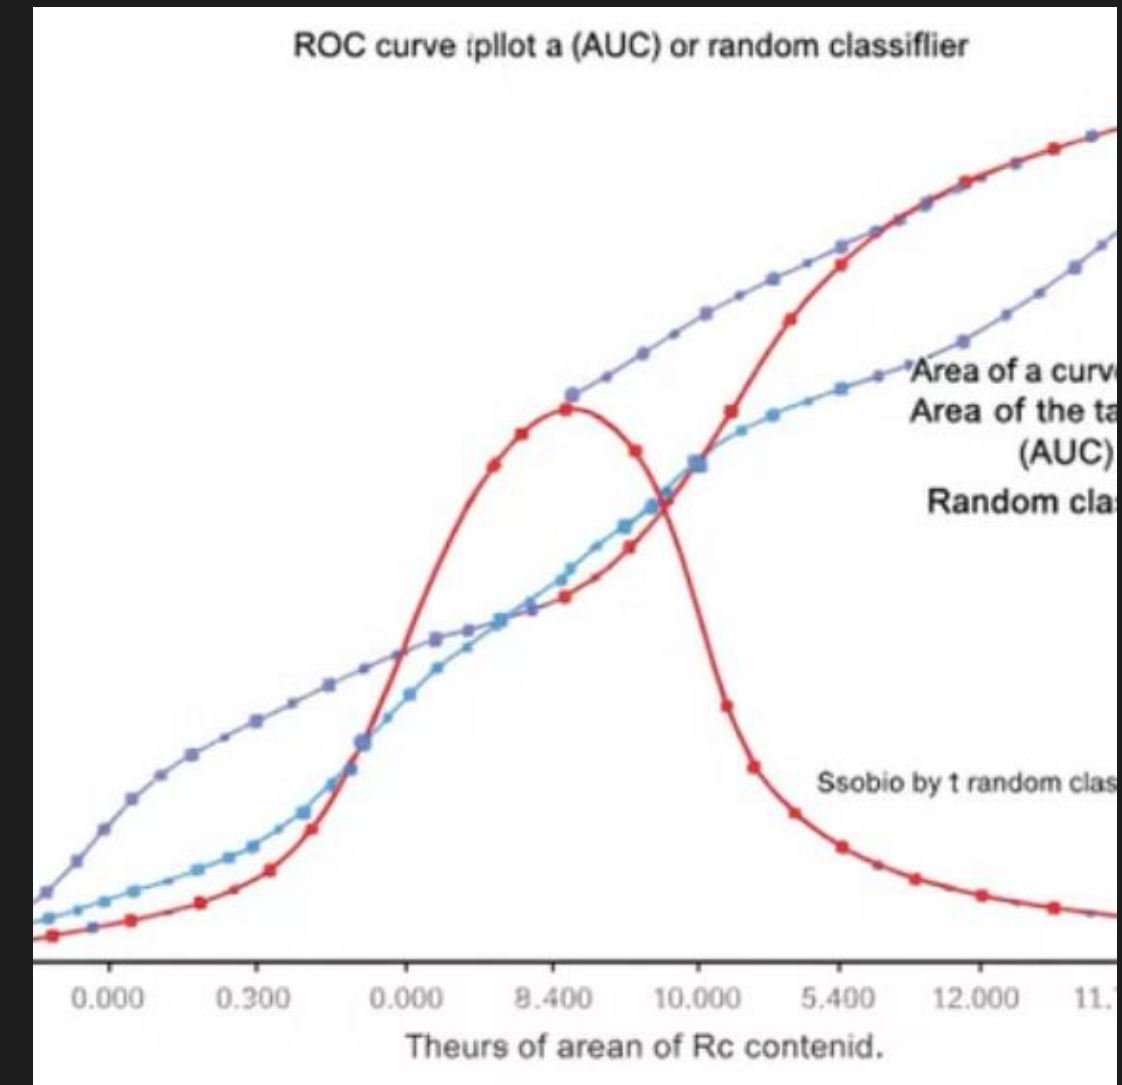
## Interpretación

Un modelo perfecto tendría una curva que pasa por (0,1). Un modelo aleatorio seguiría la diagonal desde (0,0) hasta (1,1).

# Implementación en Python

La implementación de estas métricas en Python es sencilla gracias a bibliotecas como scikit-learn. Para métricas de regresión, podemos usar funciones como `mean_squared_error`, `mean_absolute_error` y `r2_score`. Para clasificación, disponemos de `confusion_matrix`, `precision_score`, `recall_score` y `roc_auc_score`.

Estas herramientas nos permiten evaluar rápidamente nuestros modelos y visualizar su rendimiento a través de gráficos informativos como matrices de confusión coloreadas y curvas ROC.





# Ejercicio Guiado

## Requisitos:


1. Importa las librerías.
2. Carga los Datos
3. Implementa algoritmos de regresión:
  - o MAE (Error Absoluto Medio).
  - o MSE (Error Cuadrático Medio).
  - o RMSE (Raíz del Error Cuadrático Medio).
  - o  $R^2$  (Coeficiente de Determinación).
4. Implementa algoritmos de clasificación
  - o Matriz de confusión.
  - o Precisión y exactitud.
  - o Sensibilidad y especificidad.
  - o Curva ROC-AUC.
5. Comparar métodos

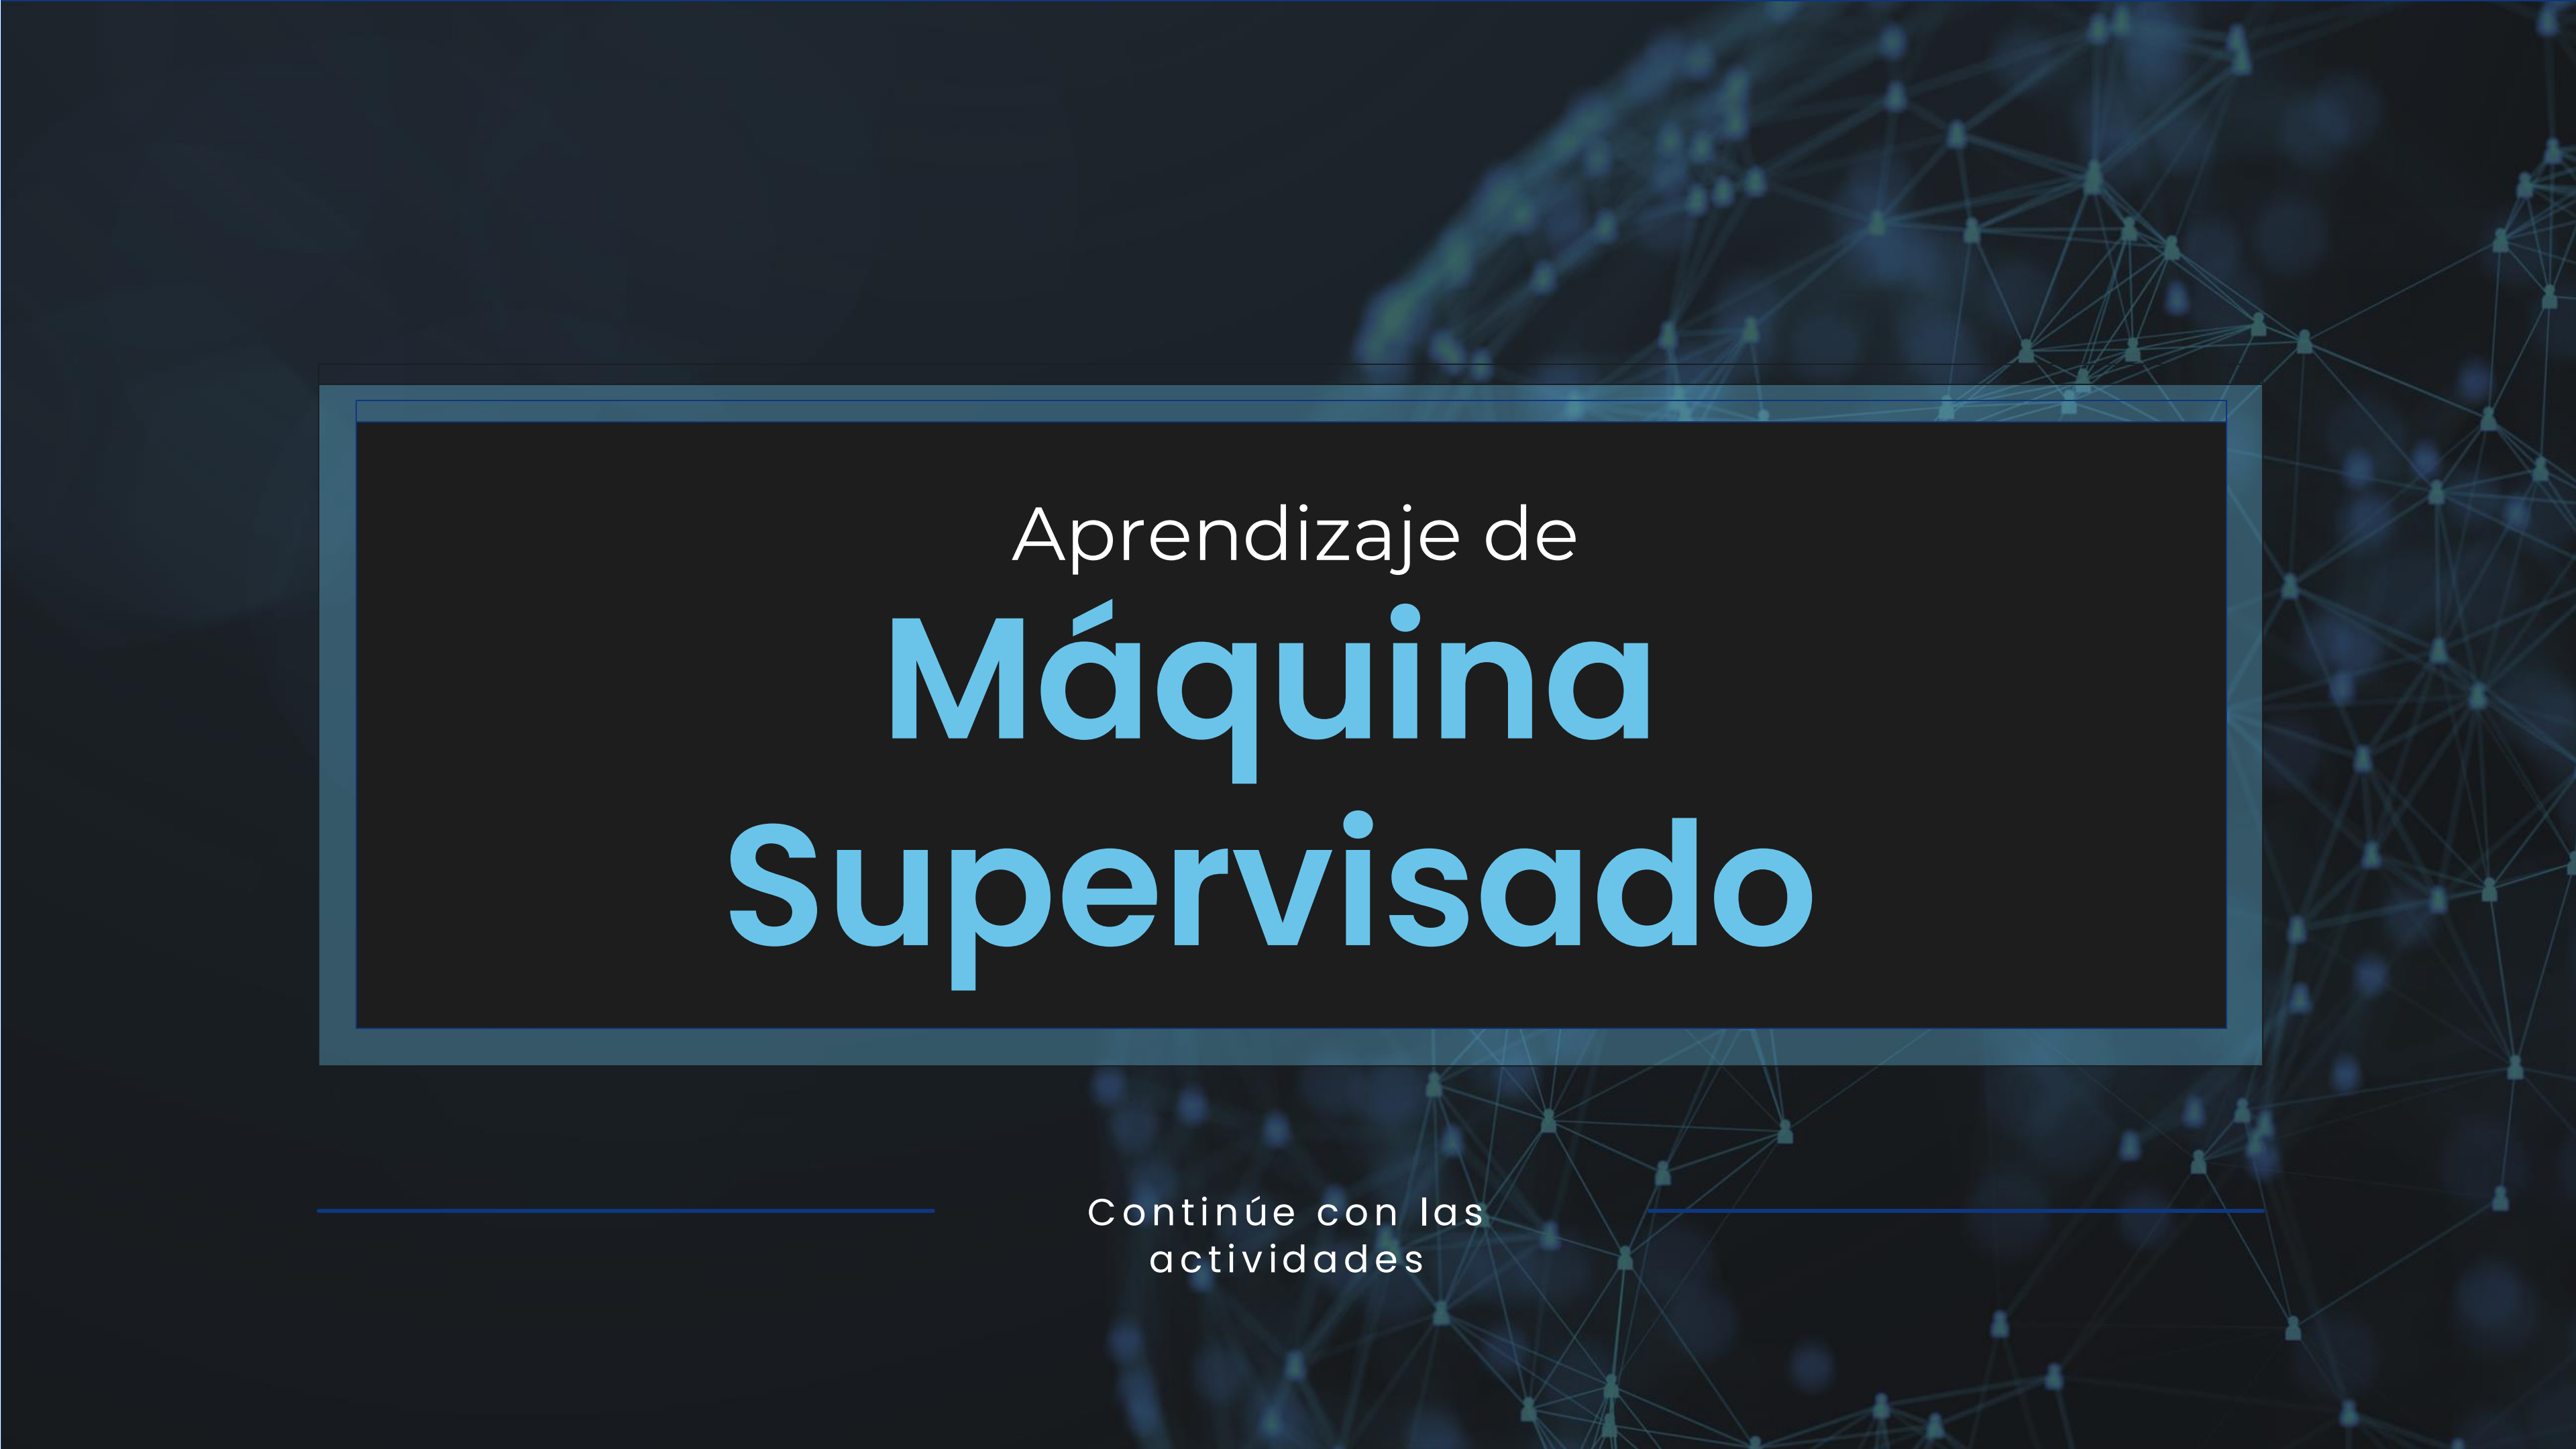


El detalle de la actividad se encuentra en guía de estudio de la sesión

# Preguntas

Sección de preguntas



A background network diagram consisting of numerous small blue nodes connected by thin, light blue lines, creating a complex web-like structure. The nodes are more densely packed in some areas and more sparse in others, with some nodes appearing slightly brighter than others.

# Aprendizaje de **Máquina Supervisado**

---

Continúe con las  
actividades

---