

A background network diagram consisting of numerous small blue nodes connected by thin, light blue lines, creating a complex web-like structure. The nodes are distributed across the entire frame, with a higher density in the upper right and lower right areas.

Fundamentos de **Deep Learning**

Sesión 5

¿Qué es una Red Neuronal Convolutiva?

Estructura de cuadrícula

Diseñada para procesar datos con estructura de cuadrícula, como imágenes.

Patrones espaciales

Detecta patrones espaciales y características jerárquicas en los datos.

Aplicaciones

Útil en visión por computadora y reconocimiento de patrones.

¿Qué es una Convolución?

Operación matemática:

Aplica un **filtro** (o kernel) a una matriz de datos para extraer características relevantes.

Características específicas:

Extrae bordes, texturas y formas de una imagen, capturando patrones locales.

Beneficios

1. Reduce parámetros

Gracias a los **kernels compartidos**, el mismo filtro se aplica a toda la imagen, reduciendo la cantidad de parámetros en comparación con las capas completamente conectadas.

2. Extrae características

Los filtros aprenden a detectar características importantes (bordes, formas, texturas).

3. Mantiene información espacial

El **stride** y la relación local entre píxeles preservan la estructura espacial de la imagen.

Conceptos Claves

Kernels Compartidos:

El mismo filtro se aplica a toda la imagen, lo que permite aprender características consistentes.

Tamaño de Filtro:

El tamaño del filtro (ej. 3x3, 5x5) define el área de la imagen sobre la cual se realiza la convolución.

Stride:

El stride controla el paso con el que el filtro se mueve sobre la imagen. Un stride de 1 mueve el filtro píxel por píxel, mientras que un stride mayor reduce la resolución de la salida.

Campo de Utilización de las CNN



Reconocimiento facial

Ej: Face ID en iPhones.



Detección de objetos

Ej: Autos autónomos.



Segmentación de imágenes

Ej: Diagnóstico en radiografías.



Etapas en las CNN

1

Convolución

- Extrae características con filtros.

2

ReLU

- Introduce no linealidad.

3

Pooling

- Reduce dimensionalidad.

4

Flattening

- Convierte a vector.

5


Fully Connected (densa)

- Combina características para la decisión.

6

Capa de salida (Softmax/Logits)

- Entrega probabilidades o valores.



Etapas Redes Neuronales Convolutivas

Actividad Práctica Guiada: Implementación de Redes Neuronales Convolutivas en Python

Entrenaremos una CNN para clasificar imágenes del conjunto de datos CIFAR-10

Requisitos:

1. Debes tener instaladas las dependencias de TensorFlow y Keras.
2. Importar las librerías.
3. Cargar y preprocesar el dataset.
4. Definir la arquitectura de la CNN.
5. Compilar y entrenar el modelo.
6. Evaluar el modelo.
7. Visualizar los resultados.



El detalle de la actividad se encuentra en la guía de estudio de la sesión.

Evaluación y Optimización de la Red Neuronal Convolutiva

1. Precisión (Accuracy)

Proporción de predicciones correctas.

Útil: Para clases balanceadas.

2. Matriz de Confusión

Visualiza aciertos y errores del modelo.

Útil: Para detectar falsos positivos y negativos.

3. Curva de Pérdida y Precisión

Evolución de precisión y pérdida durante el entrenamiento.

Útil: Para identificar overfitting o underfitting.

Métricas adicionales para datasets desbalanceados

4. Recall (Sensibilidad)

$$\text{Recall} = \frac{VP}{VP + FN}$$

Útil: Minimizar falsos negativos (ej. enfermedades).

5. F1 Score

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Útil: Combina precisión y recall, adecuado para datasets desbalanceados.

6. AUC-ROC

Evalúa el rendimiento del modelo a diferentes umbrales.

Útil: Un AUC cercano a 1 indica un modelo fuerte.

Técnicas de Optimización en CNN

- ◆ **Dropout**

Desactiva aleatoriamente un porcentaje de neuronas durante el entrenamiento para evitar el sobreajuste (overfitting).

- ◆ **Data Augmentation**

Aumenta la diversidad del dataset aplicando transformaciones (rotaciones, escalado, recortes, etc.) a las imágenes de entrenamiento, mejorando la generalización.

- ◆ **Early Stopping**

Detiene el entrenamiento cuando el rendimiento en los datos de validación deja de mejorar, evitando el sobreentrenamiento.

- ◆ **Learning Rate Scheduling**


Ajusta dinámicamente la tasa de aprendizaje (learning rate) durante el entrenamiento para una convergencia más eficiente.

- ◆ **Regularización (L1/L2)**

Agrega penalizaciones a los pesos grandes en la función de pérdida para evitar modelos demasiado complejos.

Preguntas

Sección de preguntas



The background of the slide features a complex network diagram with numerous nodes and connecting lines, rendered in a light blue color against a dark blue background. The network is dense and spans the entire width and height of the slide.

Fundamentos de **Deep Learning**

Continúe con las
actividades
